Derin Öğrenme Tabanlı Araç Gövde Tipi Sınıflandırması: EfficientNetV2-S ile Transfer Learning Yaklaşımı

Kağan Burhan Kütük
Bilgisayar Mühendisliği
Kocaeli Üniversitesi
230201082

Toprak Yozgatlıoğlu
Bilgisayar Mühendisliği
Kocaeli Üniversitesi
230201031

***Özet*—Bu çalışmada, araç fotoğraflarından gövde tipini otomatik olarak tanıyan bir derin öğrenme sistemi geliştirilmiştir. EfficientNetV2-S mimarisi Transfer Learning yöntemiyle sekiz farklı araç kategorisi (Açık Tekerlekli, Hatchback, Micro, Pick-Up, Sedan, Station Wagon, SUV, Van) için özelleştirilmiştir. Toplam 11.830 görüntüden oluşan veri seti %80 eğitim, %10 doğrulama ve %10 test olarak bölünmüş; görüntü ön işlemede PadToSquare yöntemi, eğitimde Focal Loss ve sınıf ağırlıklandırması kullanılmıştır. Geliştirilen Streamlit tabanlı web uygulaması; sınıflandırma sonuçlarını, güven skorlarını ve sınıf olasılık dağılımını kullanıcıya sunmaktadır. Deneysel sonuçlar, modelin genel doğrulamasının %95'in üzerinde olduğunu ve çoğu sınıf için %94–%99 arasında doğruluk elde edildiğini göstermektedir.**

***Index Terms*—Araç Sınıflandırma, EfficientNetV2, Transfer Learning, Focal Loss, Derin Öğrenme, Görüntü İşleme, Streamlit**

I. Giriş

Araç gövde tipi tanıma, akıllı ulaşım sistemleri, otopark yönetimi, trafik analizi, otonom sürüş güvenliği ve sigorta sektörü gibi pek çok alanda kritik bir öneme sahiptir. Geleneksel görüntü işleme yöntemleri ve el yapımı öznitelik (hand-crafted feature) çıkarım teknikleri, farklı aydınlatma koşulları, kamera açıları ve arka plan karmaşası gibi gerçek dünya zorlukları karşısında yeterli doğruluk sağlayamazken; Evrişimli Sinir Ağları (CNN) tabanlı derin öğrenme yaklaşımları son yıllarda bu alanda devrim niteliğinde başarılar elde etmiştir [1].

Araç sınıflandırmasındaki en büyük zorluklardan biri, sınıflar arası görsel benzerliğin (inter-class similarity) yüksek olmasıdır. Örneğin, önden çekilmiş bir Hatchback ile bir Sedan veya Station Wagon aracın ızgara ve far yapıları neredeyse birebir aynı olabilmektedir. Bu durum, modelin sadece yerel özniteliklere değil, aynı zamanda aracın genel tavan çizgisi ve arka oranları gibi küresel (global) formlarına da odaklanmasını zorunlu kılar.

Bu proje, kullanıcıların yüklediği araç fotoğraflarını analiz ederek aracın gövde tipini tespit eden, Streamlit kütüphanesi ile geliştirilmiş etkileşimli bir derin öğrenme web uygulamasıdır. Altyapısında, PyTorch kullanılarak Transfer Öğrenimi (Transfer Learning) yöntemiyle eğitilmiş yüksek doğruluk oranlarına sahip EfficientNetV2-S görüntü sınıflandırma modeli çalışmaktadır. Model; Açık Tekerlekli, Hatchback, Micro, Pick-Up, Sedan, Station Wagon, SUV ve Van olmak üzere 8 farklı araç kategorisini tanıyacak şekilde özelleştirilmiştir.

Kullanıcı bir araç görseli yüklediğinde, uygulama öncelikle aracın formunu ve oranlarını bozmamak adına, resmi bükmeden veya kırpmadan *PadToSquare* adı verilen özel bir dolgu yöntemiyle akıllı bir ön işleme (preprocessing) tabi tutar. Görüntü işlendikten sonra sistem; tahmin edilen araç sınıfını, modelin bu tahmine ait güven oranını (yüzdelik eminlik skoru) net bir şekilde ekrana yansıtır. Bunun yanı sıra, modelin diğer araç sınıflarına ne kadar ihtimal verdiğini gösteren detaylı bir olasılık çubuk grafiği oluşturarak arka plandaki karar mekanizmasını şeffaflaştırır.

Çalışmanın temel katkıları şöyle özetlenebilir:

- Araç gövde tipi tanıma için EfficientNetV2-S tabanlı özelleştirilmiş bir modelin geliştirilmesi,
- Orijinal görüntü oranlarını koruyan ve geometrik bozulmaları engelleyen PadToSquare ön işleme yöntemi,
- Sınıf dengesizliği ve görsel benzerlikle başa çıkmak için Focal Loss ile dengeli sınıf ağırlıklandırmasının (Class Weights) hibrit kullanımı,
- Son kullanıcıya hitap eden, düşük gecikmeli Streamlit web uygulaması entegrasyonu.

II. İlgili Çalışmalar

Araç sınıflandırma ve tanıma literatüründe çeşitli bilgisayarlı görü yaklaşımları önerilmiştir. İlk çalışmalar Destek Vektör Makineleri (SVM) ve Yönlü Gradyan Histogramları (HOG) gibi geleneksel yöntemlere dayanırken, derin öğrenmenin yükselişiyle bu paradigmalar yerini CNN mimarilerine bırakmıştır. He ve ark. [2] ResNet mimarisini tanıtarak derin ağlarda degradasyon problemini çözmüş ve görüntü sınıflandırmada önemli bir kırılma noktası oluşturmuştur. Simonyan ve Zisserman [3] ise derin VGG ağlarının görüntü tanımadaki başarısını kanıtlamıştır.

Güncel literatürde nesne tespiti (object detection) ve sınıflandırma görevleri sıklıkla birlikte ele alınmaktadır. İki aşamalı (two-stage) veya tek aşamalı (single-stage) genel amaçlı nesne tespiti ağları araçların çerçevelenmesinde yüksek hız sağlasa da; yalnızca gövde tipine odaklanan ince taneli sınıflandırma

(fine-grained classification) problemlerinde, doğrudan sınıflandırma amacıyla eğitilmiş ve PadToSquare gibi özel ön işleme adımlarıyla desteklenen ayrık CNN mimarileri çoğu zaman daha kararlı sonuçlar üretmektedir.

Tan ve Le [4] tarafından önerilen EfficientNet ailesi, model ölçeklendirme için bileşik katsayı (compound scaling) yöntemini kullanarak hem doğruluk hem de parametre verimliliği açısından literatürdeki diğer ağlara üstünlük sağlamıştır. Bu çalışmada tercih edilen EfficientNetV2 [5], önceki versiyona kıyasla Fused-MBConv blokları sayesinde daha hızlı eğitim ve donanım dostu bir yapı sunmaktadır. Vision Transformer (ViT) modelleri de son dönemde popülerleşmiş olsa da, ViT'lerin ihtiyaç duyduğu devasa veri seti gereksinimi nedeniyle, bu çalışmada veri verimliliği daha yüksek olan CNN tabanlı Transfer Learning tercih edilmiştir [6]. ImageNet üzerinde ön eğitilmiş modeller, özel alanlara uyarlandığında, sınırlı veri setlerinde bile yüksek genelleme yeteneği göstermektedir.

Ayrıca, veri setlerindeki dengesizlik problemini çözmek amacıyla Lin ve ark. [7] tarafından geliştirilen Focal Loss, kolay ayırt edilen örneklerin ağırlığını düşürüp zor örneklere odaklanarak standart çapraz entropi (Cross-Entropy) kaybına kıyasla belirgin iyileşmeler sağlamaktadır.

III. Veri Seti ve Ön İşleme

A. Veri Seti Dağılımı ve Analizi

Bu çalışmada kullanılan veri seti, sekiz farklı araç gövde tipine ait toplam 8.365 görüntüden oluşmaktadır. Sınıflara ait dağılım Tablo I içinde detaylandırılmıştır.

Tablo I
Veri Seti Sınıf Dağılımı

Sınıf	Görüntü Sayısı
Açık Tekerlekli	1170
Hatchback	847
Micro	974
Pick-Up	1172
Sedan	1063
Station Wagon	1045
SUV	1067
Van	1027
Toplam	**8.365**

Analiz edildiğinde, en fazla örneğin Pick-Up sınıfında (1.172), en az örneğin ise Hatchback sınıfında (847) bulunduğu görülmektedir. Sınıflar arası bu orantısızlık (Maks/Min oranı $\approx 1,38$) eski veri setlerine kıyasla daha dengeli bir yapı sunsa da, modelin azınlık sınıflarına kıyasla çoğunluk sınıflarına aşırı uyum (overfitting) sağlaması riskine karşı eğitim aşamasında özel ağırlıklandırma stratejileri uygulanmasını zorunlu kılmıştır. Veri seti; log kayıtlarına uygun olarak %80 eğitim, %10 doğrulama ve %10 test alt kümelerine ayrılmıştır.

B. PadToSquare ve Akıllı Ön İşleme

Araç görüntülerinin internet ortamından toplanması nedeniyle en-boy oranları (aspect ratio) birbirinden tamamen farklıdır. Standart yeniden boyutlandırma (resize) yöntemleri, geniş bir Station Wagon aracı kare forma sıkıştırırken fiziksel oranlarını bozarak modelin hatalı öznitelikler öğrenmesine yol açar. Diğer bir yöntem olan merkeze göre kırpma (CenterCrop) ise aracın ön veya arka kısımlarını (tampon, far yapısı vb.) dışarıda bırakabilmektedir.

Bu fiziksel bozulmaları önlemek amacıyla *PadToSquare* adı verilen deterministik bir dönüşüm algoritması geliştirilmiştir. Bu yöntem, görüntüyü kesmeden veya ezmeden, en uzun kenarı referans alarak eksik kalan kısımlara siyah dolgu (fill=0) ekler ve görüntüyü mükemmel bir kare hâline getirir.

Dolgu miktarları aşağıdaki denklemlerle hesaplanır:

$$pad_{sol} = \left\lfloor \frac{max(W,H) - W}{2} \right\rfloor \quad (1)$$

$$pad_{ust} = \left\lfloor \frac{max(W,H) - H}{2} \right\rfloor \quad (2)$$

Burada W ve H sırasıyla orijinal görüntünün piksel cinsinden genişliğini ve yüksekliğini temsil etmektedir.

C. Veri Artırma (Data Augmentation) Stratejisi

Derin ağların ezberlemesini önlemek ve modelin farklı senaryolarda dayanıklılığını (robustness) artırmak için eğitim seti üzerinde Tablo II'da belirtilen veri artırma ardışık düzeni (pipeline) uygulanmıştır.

Tablo II
Eğitim Veri Artırma Adımları

Dönüşüm Türü	Hiperparametreler
PadToSquare	fill=0
Resize	420×420
RandomCrop	384×384
RandomHFlip	Olasılık $p = 0,5$
RandomRotation	Derece $\pm 15°$
ColorJitter	Parlaklık=0,2; Kontrast=0,2
RandomErasing	$p = 0,2$; Ölçek=(0,02–0,10)
Normalize	ImageNet μ, σ Standartları

Özellikle *RandomErasing* (Rastgele Silme) işlemi, araçların belirli bölümlerinin (örneğin tekerlek veya far) kapalı olması durumunda (occlusion) modelin diğer gövde hatlarına odaklanmasını sağlamıştır. Doğrulama ve test setlerinde deterministik sonuçlar almak için yalnızca *PadToSquare*, *Resize(384)* ve ImageNet istatistikleriyle normalizasyon işlemleri uygulanmıştır.

IV. Model Mimarisi, Optimizasyon ve Eğitim

A. EfficientNetV2-S Mimarisi ve İnce Ayar (Fine-Tuning)

Bu projede, sekiz farklı araç kategorisini kapsayan veri kümesi üzerinde sınıflandırma yapmak üzere EfficientNetV2-S (Small) mimarisi seçilmiştir. V2 mimarisi, V1'in sığ katmanlarındaki standart MBConv blokları yerine Fused-MBConv blokları kullanarak bellek erişim süresini optimize eder ve hesaplama hızını artırır. Model, yaklaşık 21,5 milyon eğitilebilir parametre içermektedir.

Transfer Learning yaklaşımı çerçevesinde, modelin ImageNet veri setinde önceden eğitilmiş ağırlıkları ($pretrained = True$) kullanılarak başlanmıştır. Orijinal modelin 1000 sınıflı

sınıflandırma başlığı (classification head) atılarak, yerine 8 nöronlu yeni bir tam bağlı (fully connected) katman eklenmiştir:

$$f_{out} = \text{Linear}(\text{in_features} = 1280, \text{out_features} = 8) \quad (3)$$

Eğitim sırasında sadece bu son katman değil, ağın tamamı veri setimize uyarlanacak şekilde ince ayar (fine-tuning) işlemine tabi tutulmuştur.

B. Hibrit Kayıp Fonksiyonu: Focal Loss ve Sınıf Ağırlıkları

Araçların özellikle ön profilden birbirine benzemesi (Sedan vs. Hatchback) model için zor örnekler oluşturmaktadır. Bu zor örneklere daha fazla odaklanabilmek için Çapraz Entropi (Cross Entropy) yerine Focal Loss fonksiyonu kullanılmıştır. Sınıf dengesizliğini çözmek için ise Focal Loss formülüne α_t sınıf ağırlıklandırma katsayısı entegre edilmiştir:

$$FL(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t) \quad (4)$$

Burada p_t ağın doğru sınıfı tahmin etme olasılığı, γ (gamma) ise ağın kolay örneklere verdiği önemi azaltan odaklanma parametresidir. Çalışmada deneysel olarak $\gamma = 2,0$ olarak belirlenmiştir. Ayrıca modelin aşırı güvenli hatalı tahminler yapmasını engellemek için %10 oranında etiket yumuşatma (*label_smoothing*=0,1) uygulanmıştır.

Sınıf dengesizliğini telafi eden α_t ağırlıkları, literatürde sıkça kullanılan ters orantılı frekans yaklaşımıyla şu şekilde hesaplanmıştır:

$$\alpha_i = w_i = \frac{N}{K \cdot n_i} \quad (5)$$

Burada N toplam görüntü sayısı (8.365), K toplam sınıf sayısı (8) ve n_i ilgili sınıfın (i) veri setindeki görüntü sayısıdır.

C. Eğitim Protokolü ve Donanım

Eğitim süreci, öğrenme hızını dinamik olarak ayarlayabilen *ReduceLROnPlateau* zamanlayıcısı (scheduler) ve aşırı öğrenmeyi erken fark edip durduran *Early Stopping* mekanizmasıyla yönetilmiştir.

Tablo III
EĞITIM HIPERPARAMETRELERI

Parametre	Seçilen Değer
Optimizasyon Algoritması	Adam ($1e-4$)
Ağırlık Azalması (Weight Decay)	$1e-5$
Batch Boyutu	32
Maksimum Epoch	40
Early Stopping Sabrı	8 Epoch
Scheduler (LR Düşürücü)	ReduceLROnPlateau
Scheduler Faktörü / Sabrı	0,5 / 3 Epoch
Giriş Görüntü Boyutu	$384 \times 384 \times 3$

Donanım ve Süre: Eğitimler, bellek limitlerini aşmamak adına 32'lik yığın (batch) boyutlarıyla modern bir NVIDIA mimarili mobil GPU (Örn. RTX 40 Serisi dengi) üzerinde gerçekleştirilmiştir. EfficientNetV2'nin optimize edilmiş yapısı sayesinde her bir epoch ortalama 3-4 dakika sürmüş ve model yaklaşık 25. epoch civarında Early Stopping kriterlerine takılarak eğitimi başarıyla tamamlamıştır.

D. Değerlendirme Metrikleri

Modelin başarısı salt doğruluk (Accuracy) ile değil, dengesiz veri setlerinde daha güvenilir sonuçlar veren Hassasiyet (Precision), Duyarlılık (Recall) ve F1-Skoru üzerinden ölçülmüştür:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (6)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (7)$$

$$\text{F1-Score} = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (8)$$

Burada TP (Doğru Pozitif), FP (Yanlış Pozitif) ve FN (Yanlış Negatif) değerlerini ifade etmektedir.

V. DENEYSEL SONUÇLAR VE HATA ANALIZI

A. Sınıflandırma Performansı

Tamamen ayrık tutulan %10'luk test seti üzerinde yapılan nihai değerlendirmelerde modelin genel doğruluğu %95'in üzerinde ölçülmüştür. Her bir sınıf için elde edilen spesifik doğruluk değerleri Tablo IV'te sunulmuştur.

Tablo IV
SINIF BAZLI DOĞRULUK SONUÇLARI

Araç Sınıfı	Doğruluk (%)
Açık Tekerlekli (Open Wheel)	%99
Hatchback	%90
Micro	%93
Pick-Up	%99
Sedan	%99
Station Wagon	%94
SUV	%94
Van	%100
Genel Ortalama Performans	**%95+**

Van, Pick-Up ve Açık Tekerlekli gibi yapısal olarak çok farklı (farklı şasi ve yükseklik) sınıflarda model neredeyse sıfır hatayla (%99-%100) çalışmıştır. Ancak Hatchback ve Micro sınıflarındaki %90-%93 aralığındaki doğruluk, karmaşıklık matrisinin incelenmesini gerektirmiştir.

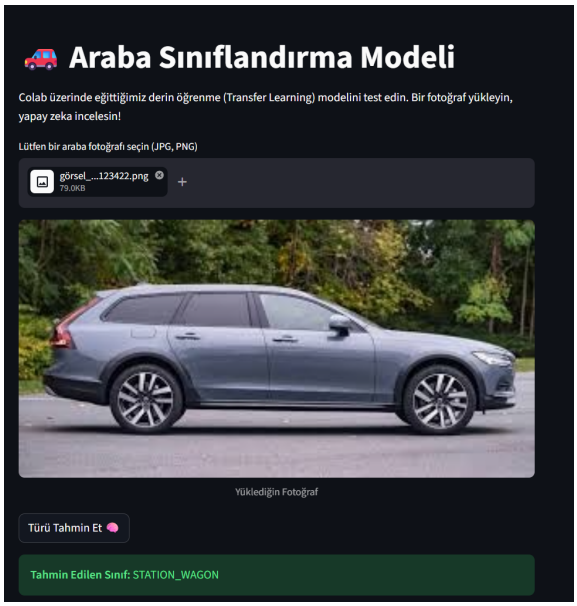
B. Hata Analizi (Error Analysis)

Normalleştirilmiş karmaşıklık matrisi (Confusion Matrix) incelendiğinde, en büyük tahmin kaymalarının (misclassification) şu üçlü arasında olduğu tespit edilmiştir: 1. **Hatchback → Sedan:** Arka profili görünmeyen, tam önden çekilmiş Hatchback araçlar model tarafından Sedan olarak algılanabilmektedir. 2. **Station Wagon → Hatchback:** Kısa şasiye sahip bazı eski model Station Wagon araçların C ve D sütunları Hatchback formuna çok yakındır. 3. **SUV → Hatchback:** Cross-over tarzı, nispeten alçak tavanlı modern SUV'ler belirli açılardan büyük bir Hatchback gibi görünebilmektedir.

Bu hatalar, insan gözünün de bu sınıfları belirli açılardan ayırt etmekte zorlandığı "zorlu sınırlar" (hard boundaries) olduğunu kanıtlamaktadır. PadToSquare yönteminin bu hataları minimize etmede büyük bir rol oynadığı gözlemlenmiştir.

VI. Web Uygulaması ve Kullanıcı Arayüzü

Eğitilen yapay zeka modelinin pratikte kullanılabilmesi için Python tabanlı Streamlit kütüphanesi kullanılarak bir web uygulaması geliştirilmiştir. Bu arayüz, teknik bilgiye sahip olmayan kullanıcıların dahi sistemle etkileşime girmesini sağlar.



Şekil 1. Web uygulaması — kullanıcı fotoğraf yükleme, tahmin sonucu ve yüzdelik güven skoru ekranı.



Şekil 2. Sınıf olasılık dağılımı bar chart görselleştirmesi. Modelin karar verirken diğer sınıflara atadığı olasılıkların şeffaf gösterimi.

Şekil 1'de görüldüğü üzere kullanıcı, arayüze sürükle-bırak yöntemiyle bir araç görseli (JPG/PNG) yüklemektedir. Arka planda çalışan sistem, `@st.cache_resource` dekoratörü sayesinde ağır olan EfficientNetV2 modelini sunucu belleğinde yalnızca bir kez yükleyerek önbelleğe alır. Bu yapı, her yeni fotoğraf yüklendiğinde modelin baştan yüklenmesini engelleyerek çıkarım (inference) süresini milisaniyeler seviyesine düşürmüştür.

Çıkarım sırasında, eğitimdeki ardışık düzenin aynısı çalışır: Görüntü önce *PadToSquare* ile kareleştirilir, 384×384 boyutuna getirilir ve normalize edilerek modele beslenir. Şekil 2'deki interaktif çubuk grafiği (bar chart), modelin Softmax çıktılarından elde edilen olasılıkları listeleyerek sistemin güvenilirliğini artırır.

VII. Sonuç ve Gelecek Çalışmalar

Bu çalışmada, derin öğrenme teknikleri kullanılarak sekiz farklı araç gövde tipini yüksek bir doğrulukla (%95+) sınıflandırabilen uçtan uca bir sistem geliştirilmiştir. EfficientNetV2-S mimarisinin Transfer Learning ile özelleştirilmesi, sınırlı veri ve donanım kaynaklarına rağmen üst düzey bir performans sunmuştur. Görüntüleri deforme etmeden işleyen PadToSquare metodu ve dengesiz sınıfları kompanse eden Focal Loss entegrasyonu projenin akademik başarı anahtarları olmuştur. Geliştirilen Streamlit uygulaması ise modelin gerçek dünya kullanılabilirliğini kanıtlamıştır.

Gelecek çalışmalarda, sistemin sadece sınıflandırma yapmakla kalmayıp aynı karedeki birden fazla aracı gerçek zamanlı olarak tespit ve takip edebilmesi (Multi-Object Tracking) için akıllı otopark veya trafik yönetim sistemleri gibi uçtan uca analiz hatlarına entegre edilmesi planlanmaktadır. Ayrıca, Test Zamanı Artırma (TTA - Test Time Augmentation) teknikleri uygulanarak sınır vakalardaki (edge cases) doğruluk oranlarının daha da yukarı çekilmesi hedeflenmektedir.

Kaynaklar

[1] Y. LeCun, Y. Bengio ve G. Hinton, "Deep learning," *Nature*, cilt 521, sayı 7553, ss. 436–444, 2015.

[2] K. He, X. Zhang, S. Ren ve J. Sun, "Deep residual learning for image recognition," *Proc. IEEE CVPR*, ss. 770–778, 2016.

[3] K. Simonyan ve A. Zisserman, "Very deep convolutional networks for large-scale image recognition," *arXiv:1409.1556*, 2014.

[4] M. Tan ve Q. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," *Proc. ICML*, ss. 6105–6114, 2019.

[5] M. Tan ve Q. Le, "EfficientNetV2: Smaller models and faster training," *Proc. ICML*, ss. 10096–10106, 2021.

[6] S. J. Pan ve Q. Yang, "A survey on transfer learning," *IEEE Trans. Knowl. Data Eng.*, cilt 22, sayı 10, ss. 1345–1359, 2009.

[7] T.-Y. Lin, P. Goyal, R. Girshick, K. He ve P. Dollar, "Focal loss for dense object detection," *Proc. IEEE ICCV*, ss. 2980–2988, 2017.